Word Embeddings
تضمين الكلمات

Bridging the Gap Between Symbols and Semantics

المحتويات

- لماذا نحتاج لل “word embeddings“ ؟

- التشابه في الفضاء المتجهي (Similarity in vector space)

- التضمين الفئوي وجداول التضمين
(Categorical Embeddings & Embedding tables)

- النماذج المدربة مسبقاً (word2vec و GloVe)

مقدمة

الفرق بين البيانات المهيكلة (structured) وغير المهيكلة (unstructured)

التحدي في معالجة اللغات الطبيعية (NLP) وكيف تتعامل الحواسيب مع الكلمات كأرقام.

Price	Floor space	Rooms	Lot size	Appartment	Row house	Corner house	Detached
250000	71	4	92	0	1	0	0
209500	98	5	123	0	1	0	0
349500	128	6	114	0	1	0	0
250000	86	4	98	0	1	0	0
419000	173	6	99	0	1	0	0
225000	83	4	67	0	1	0	0
549500	165	6	110	0	1	0	0
240000	71	4	78	0	1	0	0
340000	116	6	115	0	1	0	0

بيانات مهيكلة (structured)

بيانات غير مهيكلة (unstructured)

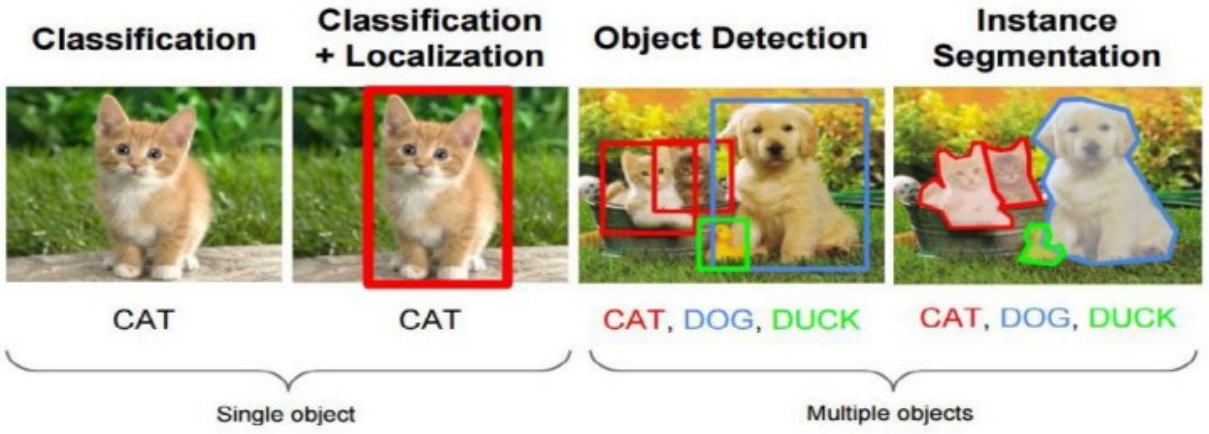

الرؤية الحاسوبية (CV) مستمرة — بينما معالجة اللغة الطبيعية (NLP) فئوية

في الرؤية الحاسوبية: الأبجدية تتكون من قيم البكسلات (0–255)
في معالجة اللغة الطبيعية: الأبجدية أو المفردات تتكون من رموز أو مؤشرات داخل القاموس

الرؤية الحاسوبية (CV)

البيانات رقمية ومستمرة بطبيعتها.

- القيم المتقاربة تعني شدات إضاءة متقاربة.
- لا تحتاج إلى خطوات إضافية لتمثيل البيانات.
- التحدي الأساسي هو فهم **العلاقات والخصائص المكانية**

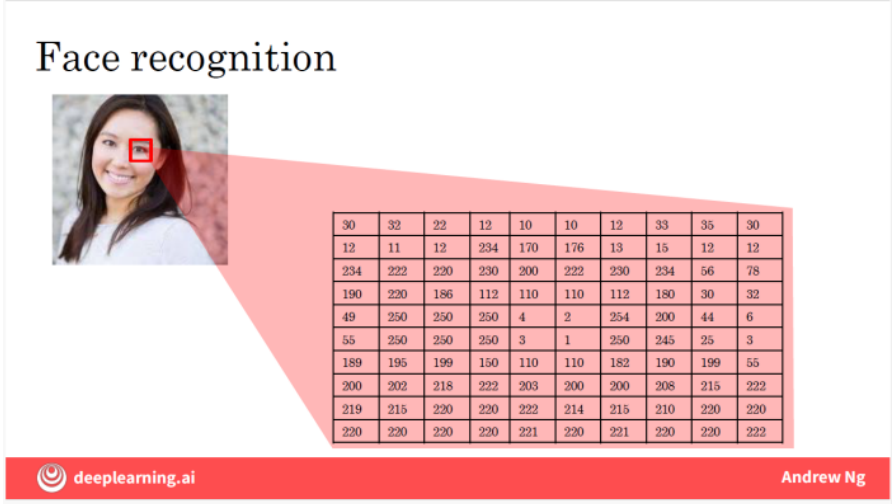

معالجة اللغة الطبيعية (NLP)

- كيف يمكن ترميز/رقمنة الرموز لكي يفهمها الحاسوب؟

- يجب أن يتضمن الترميز مفهوم التشابه بين العناصر.
- الكلمات المتشابهة يجب أن تمتلك تمثيلات متشابهة.
- ما يتبقى هو: كيف نفهم العلاقات والخصائص التسلسلية

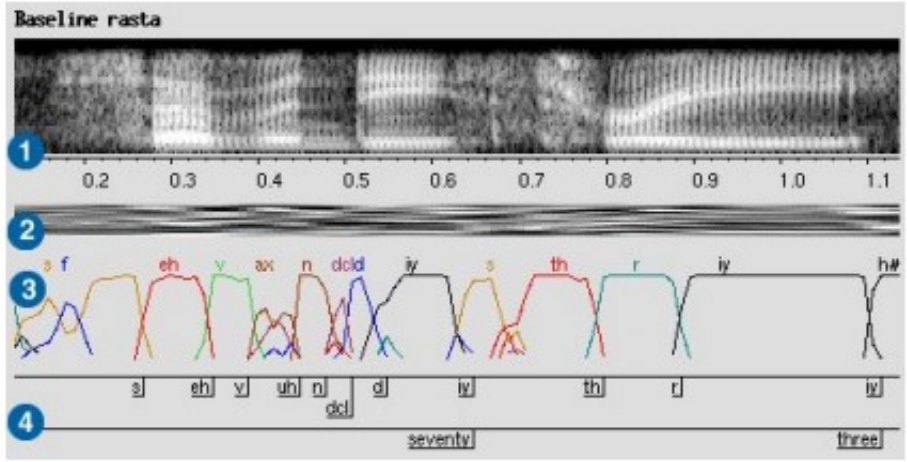

البكسلات تعتبر غير مهيكلة لكنها مهيكلة ضمنيا (و تعبر عن شدة الضوء)

يمكننا قياس مدى التشابه بين بكسلين في الفضاء المتجهي

(a) Indexing a marker area distribution.

(b) Pixel distribution (RGB = 255).

	σ_x	σ_y
1	-1	-3
2	0	-3
3	1	-3
4	-2	-2
5	-1	-2
6	0	-2
7	1	-2
8	2	-2
9	-3	-1
10	-2	-1
11	-1	-1
12	0	-1
13	1	-1
14	2	-1
15	3	-1
16	-3	0
17	-2	0
18	-1	0
19	0	0
20	1	0
21	2	0
22	3	0
23	-3	1
24	-2	1
25	-1	1
26	0	1
27	1	1
28	2	1
29	3	1
30	-2	2
31	-1	2
32	0	2
33	1	2
34	2	2
35	-1	3
36	0	3
37	1	3

(c) Linearization of marker pixel index.

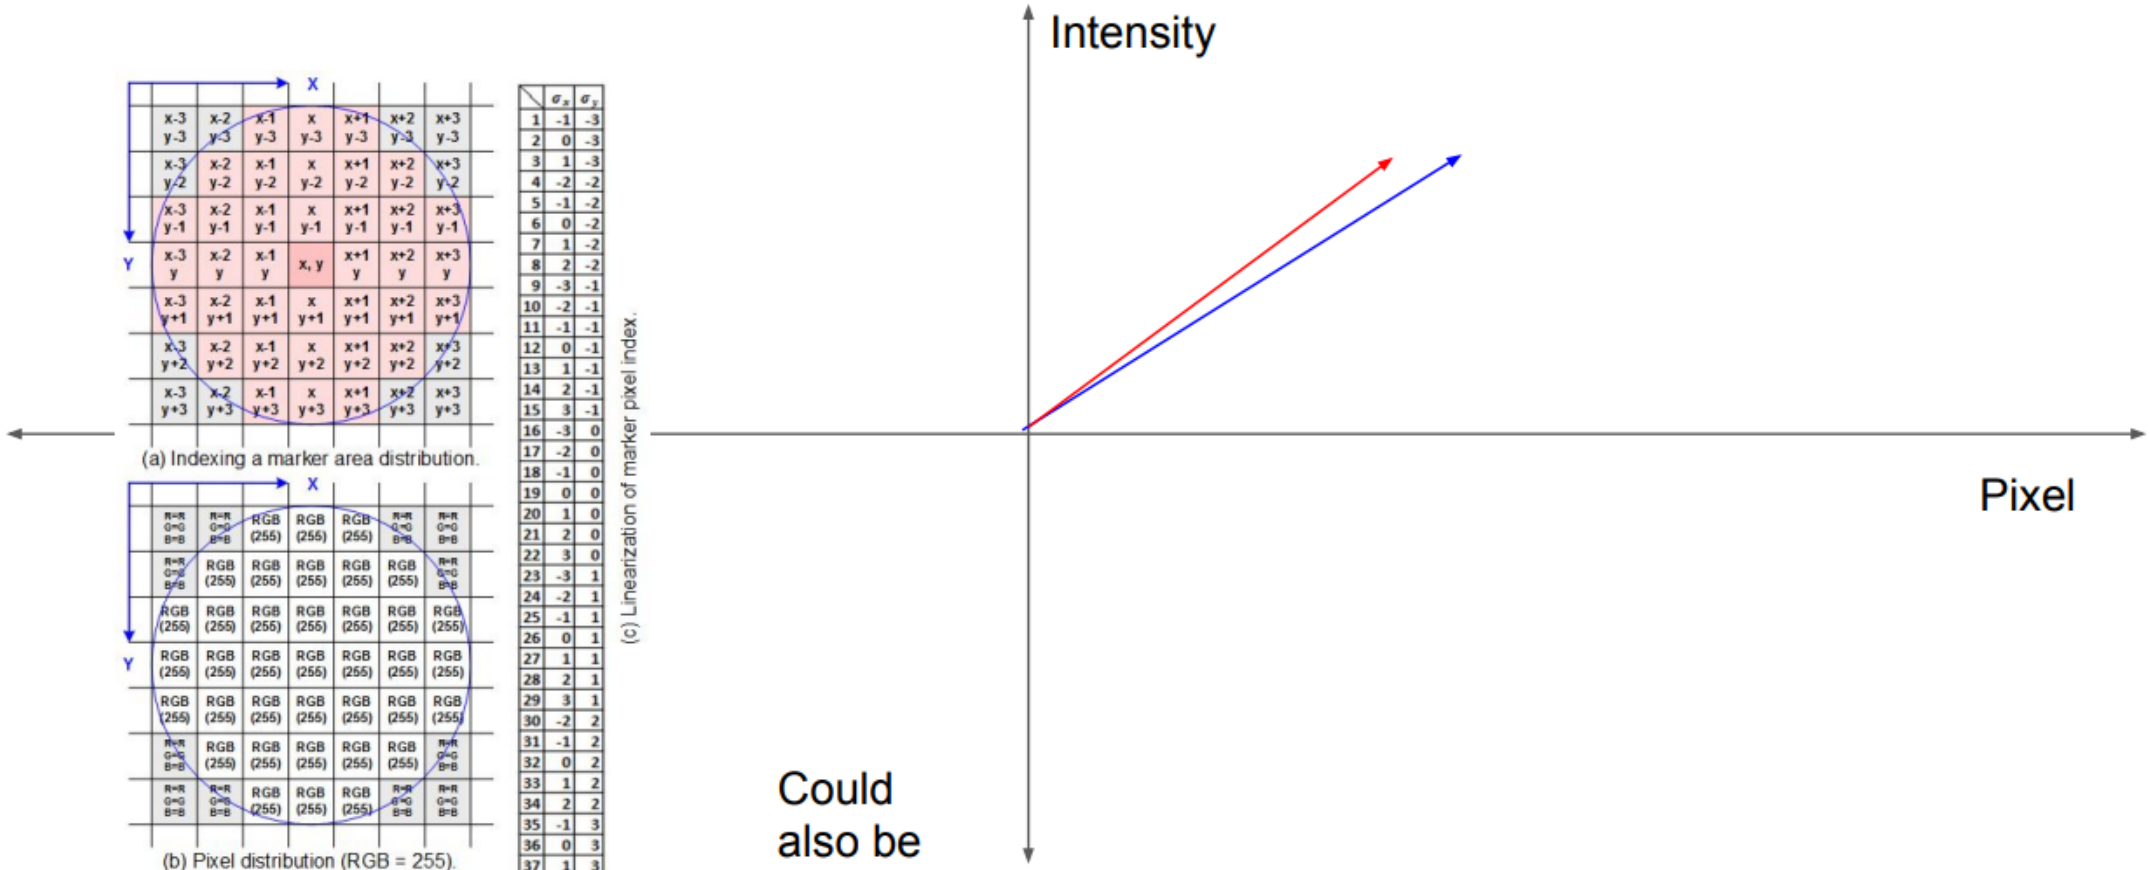

Could also be 3D space → RGB

مشكلة تمثيل الكلمات بالمؤشرات

- رقم الكلمة داخل القاموس لا يحمل معنى
- نحتاج إلى خصائص تصف الكلمات

ما الذي نحتاجه؟

- تحويل الفضاء الفئوي إلى فضاء متجهي
- الكلمات المتشابهة يجب أن تكون متقاربة
- هذا التحويل يسمى Embedding

ما هي Embeddings؟

- تمثل الكلمات باستخدام متجهات كثيفة Dense vectors
- كل بعد يمثل خاصية كامنة Latent Feature
- يتم تعلمها تلقائياً

كيف نفعل هذا ؟

- نضع طبقة Embeddingداخل النموذج
- نحسب الخسارة Loss
- يقوم المحسن Optimizerبتحديث الأوزان

بعد التدريب

- الكلمات تصبح متجهات
- الكلمات ذات المعنى المتقارب تصبح قريبة في الفضاء المتجهي
- يمكن قياس التشابه بينها

مشكلة تمثيل الكلمات باستخدام One-Hot Encoding

- كل كلمة يتم تمثيلها بمتجه يحتوي على 1 واحد والباقي أصفار
- التمثيل عالي الأبعاد Sparse
- الكلمات المتشابهة لا تمتلك أي علاقة رياضية مباشرة .
- يؤدي إلى زيادة عدد الأوزان واحتمالية الـ Overfitting.

motel = [0 0 0 0 0 0 0 0 0 0 1 0 0 0 0]
hotel = [0 0 0 0 0 0 0 1 0 0 0 0 0 0 0]

	1	2	3	4	5	6	7	8	9
man	1	0	0	0	0	0	0	0	0
woman	0	1	0	0	0	0	0	0	0
boy	0	0	1	0	0	0	0	0	0
girl	0	0	0	1	0	0	0	0	0
prince	0	0	0	0	1	0	0	0	0
princess	0	0	0	0	0	1	0	0	0
queen	0	0	0	0	0	0	1	0	0
king	0	0	0	0	0	0	0	1	0
monarch	0	0	0	0	0	0	0	0	1

Each word gets a 1x9 vector representation

كيف نحدد خصائص الكلمات؟

في Machine Learning

يتم تصميم الخصائص يدويًا. أمثلة:

- WordNet
- POS Tags
- Co-occurrence

في Deep Learning

- الشبكة تتعلم الخصائص تلقائيًا.
- نحدد فقط حجم الـ Embedding Vector.

تعلم قيم الـ Embeddings

- يتم وضع طبقة **Embedding** داخل النموذج.
- يتم حساب الخطأ **(loss)**
- يستخدم **Optimizer** لتحديث الأوزان.
- يتم التعلم باستخدام **Backpropagation**

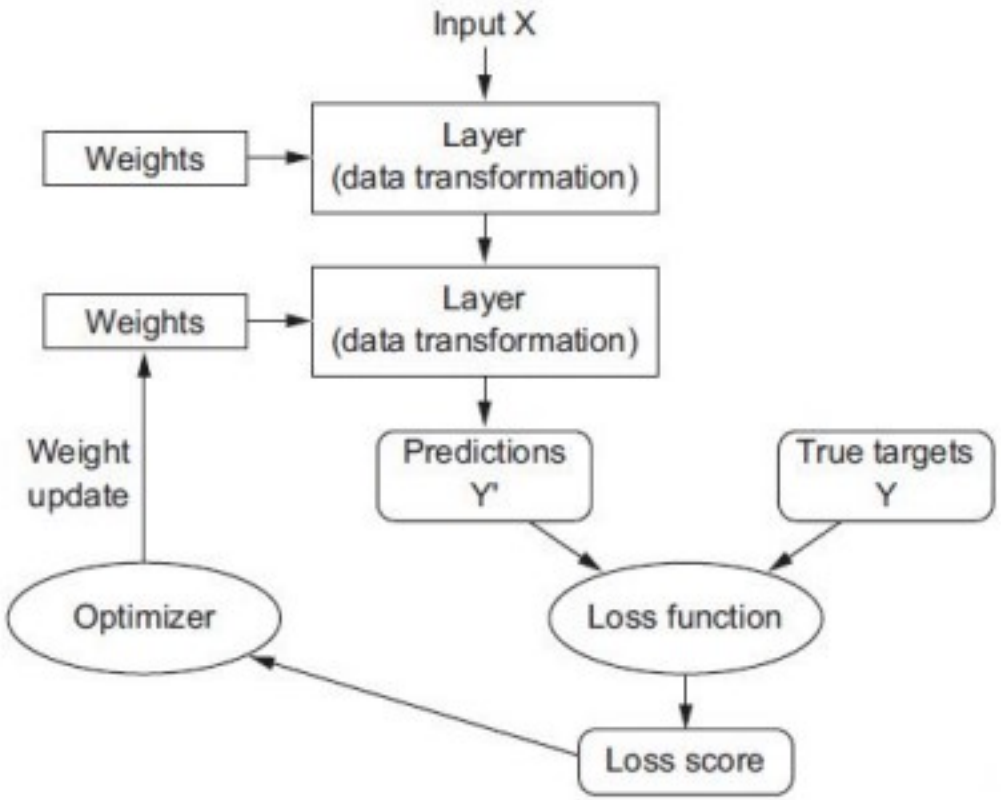

أهمية التشابه بين المتجهات

- الشبكات العصبية تعتمد على **Dot Product**
- التشابه يقاس باستخدام:
  - **Dot Product**
  - **Cosine Similarity**
  - **Euclidean Distance**

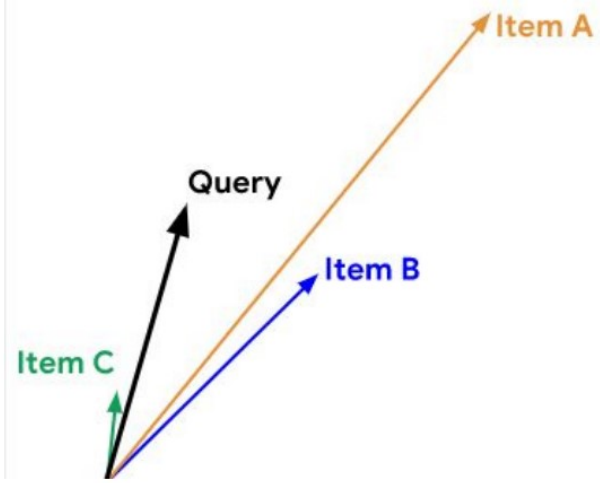

How to measure similarities

Now we represent each review with a vector |V|

How we know 2 vectors are similar?

- Dot $s(q,x) = \langle q, x \rangle = \sum_{i=1}^{d} q_i x_i$.
- Cosine similarity $s(q,x) = \|x\| \|q\| \cos(q,x)$
- Euclidean Distance $s(q,x) = \|q - x\| = \left[\sum_{i=1}^{d} (q_i - x_i)^2\right]^{\frac{1}{2}}$.

All are views of the same equation

Item

المتجهات المتشابهة تنتج قيمًا أعلى عند المقارنة.

الفرق بين البيانات الرقمية والفئوية

Numerical Features:

القيم المتقاربة تحمل معنى متقارب.

يمكن استخدامها مباشرة.

Categorical Features:

القيم مجرد رموز.

لا يوجد معنى رياضي مباشر بينها.

لذلك نحتاج **Embeddings**

مصفوفة التضمين (Embedding Matrix)

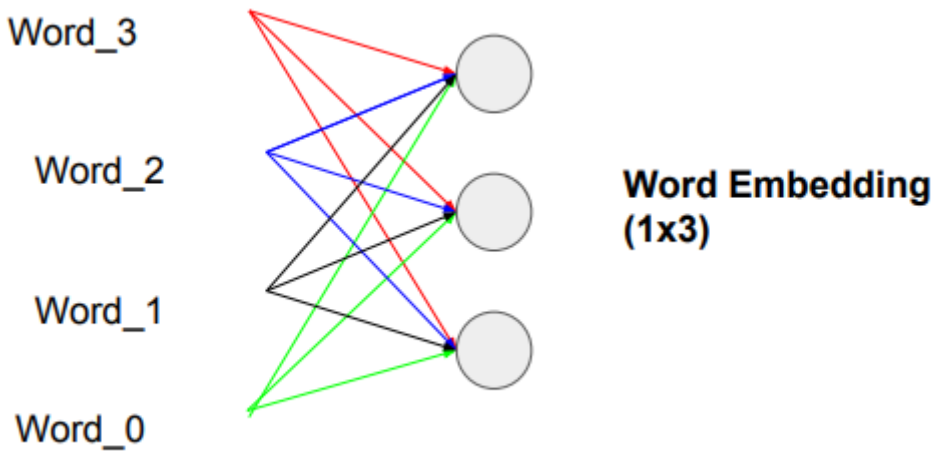

- كل صف يمثل كلمة.
- كل عمود يمثل خاصية **Feature**
- عند إدخال كلمة يتم اختيار الصف المقابل لها.
- هذا الصف هو التمثيل المتجهي للكلمة.

	E1	E2	E3
Word_0	W01	W02	W03
Word_1	W11	W12	W13
Word_2	W21	W22	W23
Word_3	W31	W32	W33

ماذا حتى الآن؟

- لكلمات ليست أرقامًا ذات معنى مباشر.
- نحتاج تحويل الكلمات إلى متجهات كثيفة Dense vectors
- الـ Embeddingsتحفظ التشابه بين الكلمات.
- الشبكات العصبية تتعلم هذه التمثيلات تلقائيًا.

لماذا تعمل Bag of Words أحيانًا؟

- تمثل الجملة بدلًا من تمثيل كل كلمة منفردة.
- الجمل المتشابهة تشترك في كلمات متقاربة.
- لكنها ما زالت تعاني من:
  - Sparsity
  - فقدان ترتيب الكلمات
  - غياب السياق

Thank You